

# AIBERT

Мотивация: После выхода [BERT](#) в 2018 году, который получился хорошей моделью для своих задач, но из-за его размеров (340 миллионов параметров). Что препятствовало его развертыванию, процессу обучения и масштабируемости. Поэтому ребята из Гугла захотели решить эти проблемы.

## Архитектура

### Factorized embedding parameterization

Как это было в BERT, да и вроде вообще всегда: у нас есть Vocab размером  $VocabSize * EmbedDim$ , то есть из one-hot вектора токена мы получаем его эмбединг. Причем в оригинальном BERT использовались вектора WordPiece(не помню про них, позднее дополню, НО! они были обучены независимо от контекста). И при этом размерность скрытого слоя  $H$  совпадала с размерностью эмбединга WordPiece, что не до конца эффективно, так как мы хотим получить эмбединги, которые отражали бы контекст, то интуитивно понятно что у этих эмбедингов размерность должна быть больше чем у эмбедингов без контекста(WordPiece). Можно было бы просто увеличить размерность эмбединга, но тогда наша матрица, размеры которой  $VocabSize * EmbedDim$  росла бы очень быстро, что некруто, так как ваще хотели оптимизировать скорость/потребление памяти.



Итого: в [BERT](#) размерность словаря равна 30000, размерность эмбединга 768. Размер матрицы: 30000 x 768. Авторы AIBERT оптимизировали это следующим хакем: разбили матрицу размеров  $V * H$ , при том  $H = E = 768$  в BERT-Base, на две матрицы размерами  $V * E$  и  $E * H$ . Что при  $E = 128$  и  $H = 768$  уменьшило кол-во параметров на ~40%

### Cross-Layer Parameter Sharing

В каждом слое трансформера используются одни и те же матрицы  $Q, K, V$ , а также матрицы  $W$  в feed-forward слое, что очень сильно экономит размеры модели. Например, в ALBERT Large, при 24 слоях, было бы 24 уникальных набора параметров для self-attention и feed-forward сетей, но с используется только один набор. Причем такая модель все еще показывает результаты лучше [BERT](#) на многих задачах

Model		Parameters	Layers	Hidden	Embedding	Parameter-sharing
BERT	base	108M	12	768	768	False
	large	334M	24	1024	1024	False
ALBERT	base	12M	12	768	128	True
	large	18M	24	1024	128	True
	xlarge	60M	24	2048	128	True
	xxlarge	235M	12	4096	128	True

Также было замечено следующее: расстояния между выходными эмбедингами на различных слоях модели **гораздо** более стабильны, если сравнивать с [BERT](#). Что говорит о том, что такой прием помогает сделать обучение нейросети более стабильным.



В BERT  $L2$  и косинусные расстояния между эмбедингами на разных слоях даже после 24 слоя все еще очень нестабильны.

## Задачи обучения

Также в процессе обучения было решено решать задачу SOP(Sentence Order Prediction) вместо NSP(Next Sentence Prediction). Дается два предложения и надо понять какое у них взаимное расположение. Т.е. предложение 2 идет после предложения 1 или наоборот.

Если для решения задачи NSP требовалось лишь верхнеуровнево понять связаны ли два предложения, то для решения задачи SOP требуется улавливать связь внутри текста. Таким образом, SOP является более сложной задачей, так как требует от модели не только понимания связи между сегментами, но и их правильного порядка, что может быть более полезно для задач, где важна логическая структура текста.

P.S. задача MLM никуда не ушла, она так же решалась