

Attention is all you need..

Архитектура

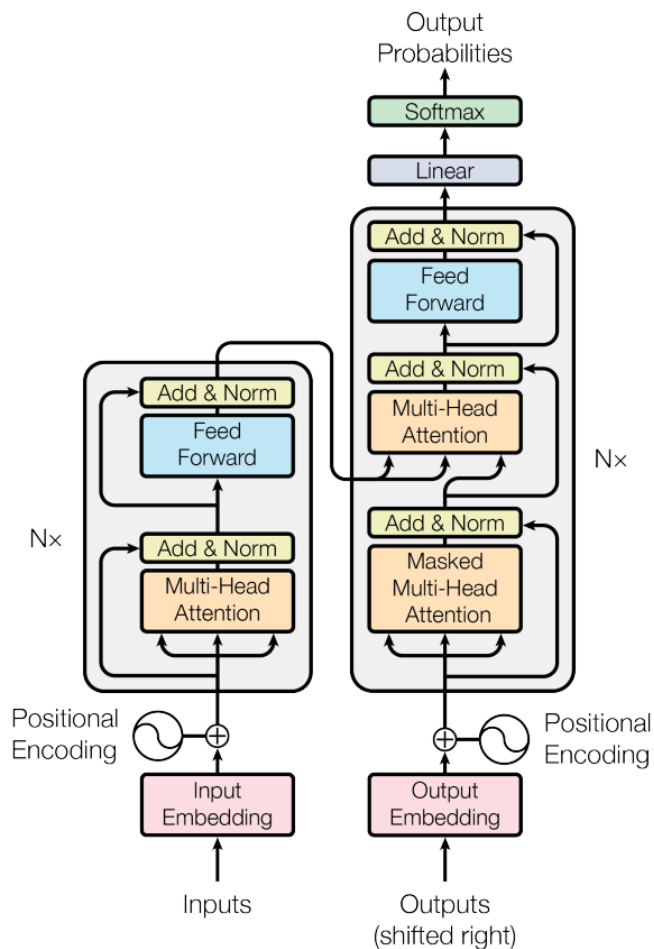


Figure 1: The Transformer - model architecture.

Архитектура модели трансформера. Как видно он состоит из двух компонентов: энкодер и декодер. В оригинальной статье используется 6 encoder layers и 6 decoder layers.


Encoder layer состоит из двух sub-layers: Multi-Head Attention и Feed Forward. Также после каждого из них прокидываются inputs(residual-connection) и на выходы Feed Forward применяется LayerNorm.

Decoder же состоит из трех sub-layers, к Attention и LayerNorm добавляется Attention, применяемый к выходам Encoder'а. Также здесь максированный Attention, который маскирует все токены меньше i , гарантируя то, что при предсказании следующего токена модель будет обладать информацией о токенах только с предыдущих позиций.

Attention

В оригинальной статье используется Scaled-DotProduct Attention, который позднее изменится на Flash Attention и др. (так как они быстрее и занимают меньше памяти).

Scaled Dot-Product Attention



$$Attention(Q, K, V) = softmax(QK^T / \sqrt{d^k}) * V$$

Интуиция - все что под softmax это вычисление весов, с которыми мы берем эмбединги из V.

Нормализация на $\sqrt{d^k}$ нужна так как при больших размерах векторов(d^k), output softmax попадают в область с градиентами близкими к нулю.

P.S To illustrate why the dot products get large, assume that the components of q and k are independent random variables with mean 0 and variance 1. Then their dot product, $q \cdot k = \sum_{i=1}^d q_i k_i$, has mean 0 and variance d .

Сложность Scaled-DotProduct Attn $O(n^2)$, что решается в...

Multi-Head Attention

Работает хорошо - масштабируем. Разные головы выявляют разные паттерны. "Голова" - одна тройка матриц Q, K, V. В оригинальной статье используется 8 голов.

Можно представить все в виде матричного умножения следующим образом

$$MultiHead(Q, K, V) = Concat(head_1, \dots, head_h) W^o$$

где $head_i = Attention(QW_i^Q, KW_i^K, VW_i^V)$, QKV - линейный обучаемый слой, а матрицы W имеют следующие размерности:


Where the projections are parameter matrices $W_i^Q \in \mathbb{R}^{d_{\text{model}} \times d_k}$, $W_i^K \in \mathbb{R}^{d_{\text{model}} \times d_k}$, $W_i^V \in \mathbb{R}^{d_{\text{model}} \times d_v}$ and $W^O \in \mathbb{R}^{h d_v \times d_{\text{model}}}$.

In this work we employ $h = 8$ parallel attention layers, or heads. For each of these we use $d_k = d_v = d_{\text{model}}/h = 64$. Due to the reduced dimension of each head, the total computational cost is similar to that of single-head attention with full dimensionality.

Feed Forward layer

$$FFN(x) = \max(0, xW_1 + b_1)W_2 + b_2$$

Идея feed-forward слоя в том что мы "разжимаем" входящий эмбеддинг в пространство большей размерности, после "сжимая" его обратно



В оригинальной статье $d_m = 512$, а $d_{ff} = 2048$