

BERT

- **Количество слоев (трансформеров):** 12
- **Размер скрытых слоев:** 768
- **Количество голов внимания в каждом слое:** 12
- **Общее количество параметров:** 110 миллионов
- **Vocab size:** 30 000

Идея: использовать bidirectional encoder, который позволяет смотреть на слова как слева-направо так и справа-налево. И получать информативные эмбединги, которые после этого могут быть использованы в downstream tasks, не изменяя архитектуру модели, а изменив лишь финальный слой получить SOTA результаты во многих NLP задачах.

Обучался на задачах NSP(Next Sentence Prediction) и MLM(Masked Language Modeling)

NSP

Взяли датасет, состоящий из пар предложений A и B, разделенные токеном [SEP]. В 50% случаев предложение B действительно идет за предложением A и ставится label IsNext, в 50% ставится label NotNext.

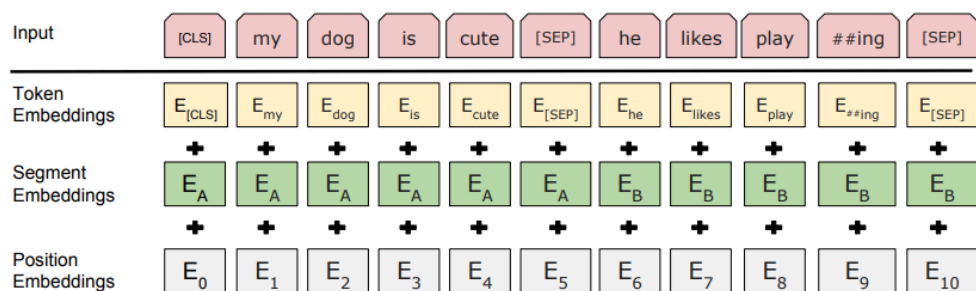


Figure 2: BERT input representation. The input embeddings are the sum of the token embeddings, the segmentation embeddings and the position embeddings.

Каждый эмбединг является суммой токена эмбединга, токена сегмента, эмбединга позиции.

MLM

Задача предсказать индекс замаскированного токена.

15% токенов случайным образом заменяются по следующей стратегии:

- в 80% случаях заменяются на токен [MASK]
- в 10% процентах случаев на любой случайный токен
- 10% токен не изменяется

Для чего?

Если бы все время использовался токен [MASK], модель бы "привыкала" к такому поведению, которое не отражает реальных данных, т.е. модель лучше генерализуется

Input = [CLS] the man went to [MASK] store [SEP]

he bought a gallon [MASK] milk [SEP]

Label = IsNext

Input = [CLS] the man [MASK] to the store [SEP]

penguin [MASK] are flight ##less birds [SEP]

Label = NotNext