


Мотивация

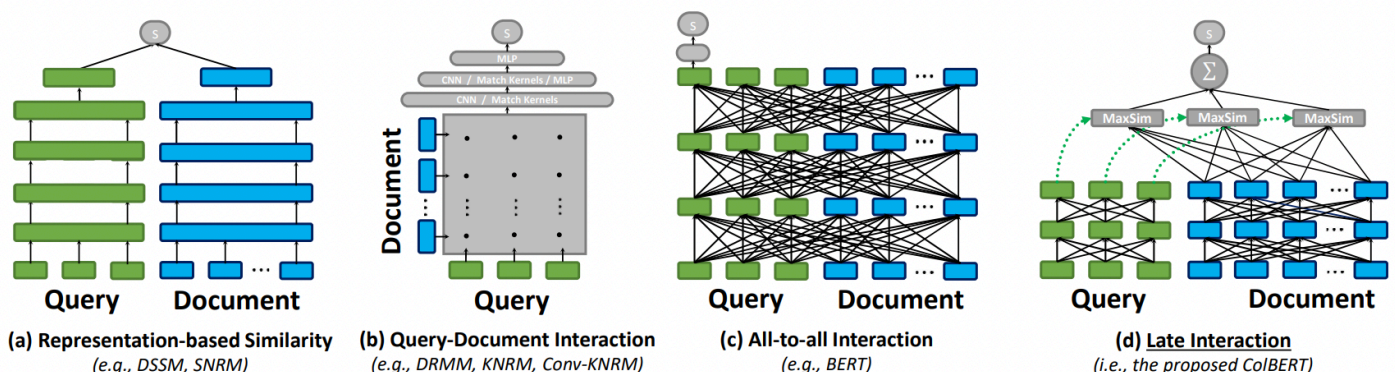
В задаче *IR* набирает популярность *BERT*, который показывают высокую эффективность в сравнении с другими методами, но computational costs растут в десятки раз, так как при использовании такого подхода нам необходимо проскорить каждую d (document) - q (query) пару. Авторы предлагают алгоритм который сначала независимо обрабатывает *query* и *document*, с эмбедингами которых позднее производит *pruning-friendly* операции, при которых не нужно рассматривать каждого возможного кандидата.



Примечание: под "NLU augmentation" подразумевается техника расширения, перефразы начального вопроса для большего покрытия

По результатам бенчмарка видно, что *ColBERT* позволяет достичь результатов сопоставимых с *BERT*, но обладает гораздо лучшей скоростью.

Так как *BERT* не позволял использовать его в production из-за высокой latency, производились исследования с аугментацией изначальных вопросов с целью лучшего поиска.



На картинке выше схематично представлены существующие подходы в решении данной задачи.

a) *Representation-focused rankers*, которые независимо получают эмбединги q и d и рассчитывают similarity score между двумя векторами. Такой подход используется в DSSM, где эмбединги запроса и документа считаются независимо, благодаря чему документы запросов можно предварительно посчитать в оффлайне.

b) *Interaction-based rankers*, которые в отличие от варианта a эмбеddят не полностью текст, а отдельные слова, фразы, из эмбеddингов которых составляется матрица размерности $d_shape \times q_shape$, которая позднее обрабатывается с помощью нейронной сети(CNN, MLP, Kernels).

c) *All-to-all interaction*. Модель, которая одновременно обрабатывает *query* и *document*(cross-encoder с transformer)

Пример:

```
[CLS] query_token_1 query_token_2 ... [SEP] document_token_1
document_token_2 ... [SEP]
```

Данная архитектура позволяет достичь высокой точности, но требует больше вычислительных ресурсов

ColBERT

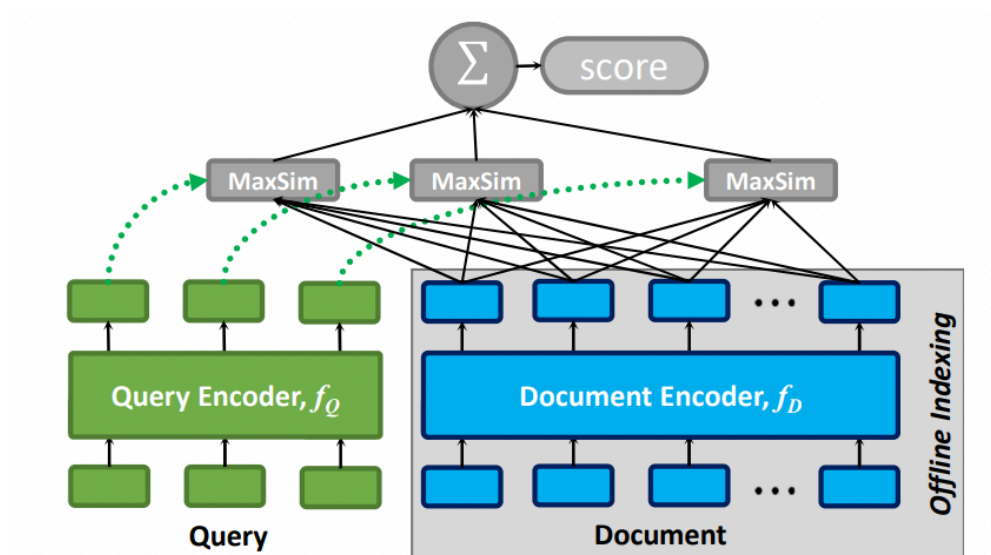


Figure 3: The general architecture of ColBERT given a query q and a document d .

Рисунок 3: архитектура ColBERT

Объяснение архитектуры ColBERT

1. Кодирование запросов и документов:

- Запрос q преобразуется энкодером f_Q в набор эмбеддингов E_q .
- Документ d преобразуется энкодером f_D в набор эмбеддингов E_d .
- Каждый эмбеддинг внутри E_q и E_d учитывает контекст остальных терминов внутри запроса и документа соответственно.

2. Late Interaction (позднее взаимодействие):

- Для эмбеддинга каждого токена $v \in E_q$ из запроса ищется **максимальное сходство** с эмбеддингами в E_d (эмбеддинги документа). Это сходство вычисляется с использованием метрики:
 - **Косинусное сходство**.
 - **L2 расстояние** (в качестве альтернативы).
- Результат сходства между v и E_d называется **MaxSim**.

3. Итоговая оценка релевантности:

- После вычисления максимального сходства для всех эмбеддингов из E_q эти значения суммируются, чтобы получить финальный скор релевантности между запросом q и документом d .

4. Интуитивный смысл:

- Каждый термин t_q из запроса мягко ищет наиболее подходящий термин t_d в документе.
- Сила соответствия между t_q и t_d определяется через самое большое сходство.
- Финальный релевантный скор оценивает, насколько документ в целом "покрывает" запрос, агрегируя эти локальные совпадения.

5. Формула для представления запроса:

$$E_q = \text{Normalize}(\text{Linear}(\text{BERT}("\text{[Q]} q_0 q_1 \dots q_l \#\#\dots\#\text{[Q]}")))$$

6. Формула для представления документа:

$$E_d = \text{Filter}(\text{Normalize}(\text{Linear}(\text{BERT}("\text{[D]} d_0 d_1 \dots d_n\text{[D]}"))))$$

7. Формула, описывающая Late Interaction:

$$S_{q,d} := \sum_{i \in |E_q|} \max_{j \in |E_d|} E_{q_i} \cdot E_{d_j}^T$$