

LaBSE

Мотивация

Создание новых супер крутых эмбедингов для мультязычных задач, используя лучшие современные методы, такие как [BERT](#) и его варианты.

Архитектура

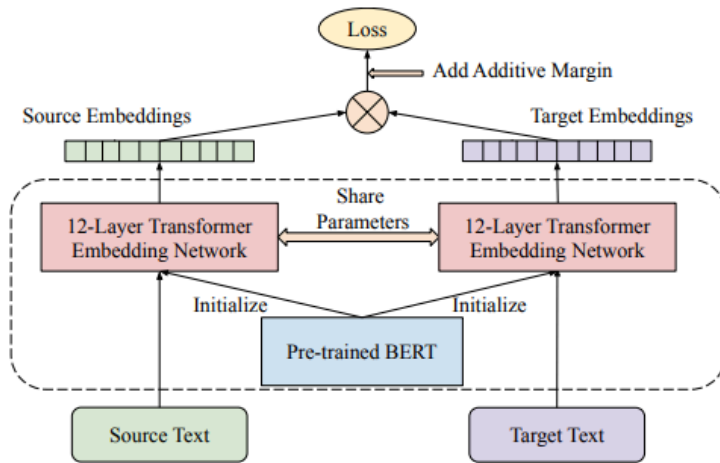


Figure 1: Dual encoder model with BERT based encoding modules.

Используется два энкодера из BERT, один из них получает эмбединг текста на исходном языке, второй же на целевом языке. После чего от этих эмбедингов вычисляется следующий лосс:

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \log \frac{e^{\phi(x_i, y_i)}}{e^{\phi(x_i, y_i)} + \sum_{n=1, n \neq i}^N e^{\phi(x_i, y_n)}}$$

Здесь $\phi(x_i, y_i)$ функция близости, обычно это dot-product $\phi(x, y) = xy^T$. Используется batch negative sampling, то есть в батче один правильный пример, и N-1 negative примеров, которые выбираются случайным образом. Таким образом, чем ближе эмбединги одного и того же текста на разных языках, и чем дальше негативные примеры, тем более будет дробь под log, что нам и нужно так как перед ней стоит минус. Можно заметить, что эта лосс функция несимметрична, относительно source и target языков, то есть мы берем только source-target перевод, для симметричности добавляется второе слагаемое, которое является тем же самым, только в обратном направлении.

Итого лосс выглядит следующим образом:

$$\bar{\mathcal{L}} = \mathcal{L}' + \mathcal{L}$$

Также добавляется отступ m , благодаря которому получается еще лучше разделять эмбединги.

$$\phi'(x_i, y_j) = \begin{cases} \phi(x_i, y_j) - m & \text{если } i = j \\ \phi(x_i, y_j) & \text{если } i \neq j \end{cases}$$

Из формулы видно что отступ вынуждает быть значение функции ϕ быть еще больше.

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \log \frac{e^{\phi(x_i, y_i) - m}}{e^{\phi(x_i, y_i) - m} + \sum_{n=1, n \neq i}^N e^{\phi(x_i, y_n)}}$$

Cross-Accelerator Negative Sampling

Для лучшего разделения примеров используется Negative Sampling. Чем больше в нем будет негативных примеров, тем лучше, но упираемся в ограничение по ресурсам на одно ядро. Cross-Accelerator Negative Sampling позволяет обмениваться отрицательными примерами между различными устройствами. Вместо того чтобы ограничиваться отрицательными примерами на одном GPU, модель использует отрицательные примеры с других GPU, увеличивая разнообразие данных.

