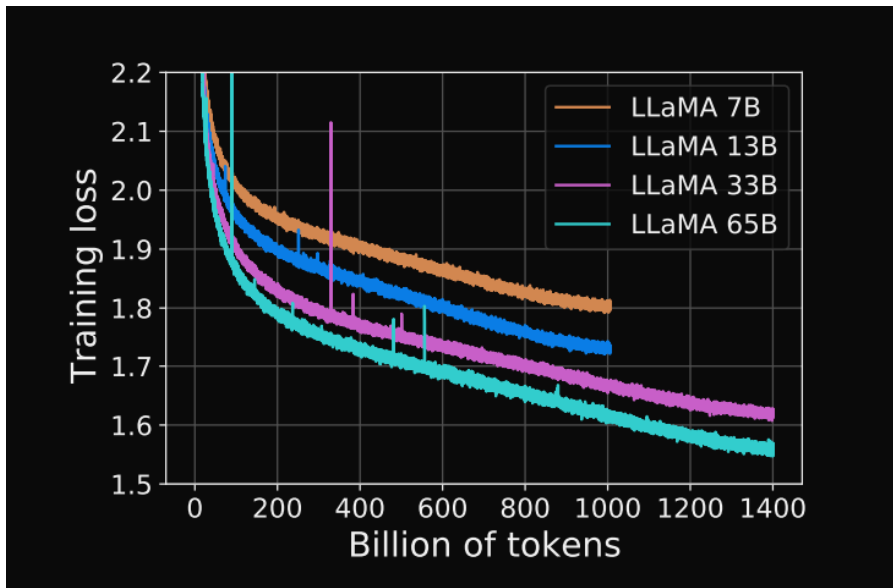


# LLaMA - Large Language Model META AI

Фокус и идея этой работы в том, чтобы

- обучить модель только на публичных датасетах, то есть сделать OpenSource модель которая сможет соревноваться с лучшими моделями того временного промежутка(2023 г.)
- обучить серию моделей, которые будут лучшими в своем inference budget
- обучать модели на большем кол-ве токенов, чем это делалось обычно



## Данные для обучения

Dataset	Sampling prop.	Epochs	Disk size
CommonCrawl	67.0%	1.10	3.3 TB
C4	15.0%	1.06	783 GB
Github	4.5%	0.64	328 GB
Wikipedia	4.5%	2.45	83 GB
Books	4.5%	2.23	85 GB
ArXiv	2.5%	1.06	92 GB
StackExchange	2.0%	1.03	78 GB

## Конфигурации моделей:

params	dimension	$n$ heads	$n$ layers	learning rate	batch size	$n$ tokens
6.7B	4096	32	32	$3.0e^{-4}$	4M	1.0T
13.0B	5120	40	40	$3.0e^{-4}$	4M	1.0T
32.5B	6656	52	60	$1.5e^{-4}$	4M	1.4T
65.2B	8192	64	80	$1.5e^{-4}$	4M	1.4T

Table 2: Model sizes, architectures, and optimization hyper-parameters.

## Архитектура

- В отличие от оригинальной статьи [Attention is all you need...](#), где Add&Norm слой стоит **после** каждого MultiHeadAttention и FeedForward, слой нормализации стоит **перед** каждым из этих слоев, используют [RMSNorm and LayerNorm](#)
- Вместо ReLU в качестве функции активации используется **SwishGLU**
- Вместо абсолютных позиционных эмбеддингов используются [RoPE](#)
- Используется оптимизированный attention из xformers, который не рассчитывает attention scores для токенов, которые позднее будут маскированы