

LLM.int8()

Мотивация

LLM становятся все больше, на момент статьи(2022 год) вышли модели PaLM(540B) и BLOOM(176B), чтобы заинференсить вторую необходимо 8 штук A100, чтоб зафайнтюнить 72:) Поэтому нужна квантизация!

Квантизация — это процесс преобразования данных из высокоточной формы (например, чисел с плавающей запятой) в более низкоточную форму (например, целые числа) для уменьшения объема памяти и ускорения вычислений. В контексте глубокого обучения это означает замену весов и входных данных нейронных сетей, представленных в формате с плавающей запятой (например, FP32 или FP16), на целочисленное представление (например, int8).

Авторы замечают что в LLM размером 6.7B возникает ~150000 экстремальных значений, то есть тех ктоорые выбиваются из распределения конкретного признака, также они отмечают, что если занулить эти экстремальные значения, то значение *softmax* у top-1 токена на ~20%, также значительно возрастает перплексия(600-1000%). В то время как если занулить такое же количество каких то других признаков, перплеския возрастает всего на 0.1%.

Из этого мы понимаем невероятную важность этих значений и что с ними надо работать иначе.

Mixed precision quantization

Следовательно, если мы квантизуем эти значения в *int8*, мы сильно потеряем в качестве. Поэтому авторы предлагают следующий подход: оставлять такие экстремальные

значения в FP16, а остальные при умножении матриц квантизовать в *int8*.





Figure 2: Schematic of LLM.int8(). Given 16-bit floating-point inputs X_{f16} and weights W_{f16} , the features and weights are decomposed into sub-matrices of large magnitude features and other values. The outlier feature matrices are multiplied in 16-bit. All other values are multiplied in 8-bit. We perform 8-bit vector-wise multiplication by scaling by row and column-wise absolute maximum of C_x and C_w and then quantizing the outputs to Int8. The Int32 matrix multiplication outputs Out_{i32} are dequantization by the outer product of the normalization constants $C_x \otimes C_w$. Finally, both outlier and regular outputs are accumulated in 16-bit floating point outputs.

В матрице X выбросы выбираются по столбцам, в матрице весов W по строкам.


Что считают выбросом?

Для трансформера с L слоями, размерностью *hiddenstate* h , размерностью последовательности S выбросом считается признак, который удовлетворяет следующим критериям:

- величина не менее 6 (было выбрано эмперически)
- присутствует не менее чем в 25% слоев трансформера(L)
- затрагивает не менее 6% последовательности(S)



(a)



(b)

Из этих двух графиков можно увидеть следующее:

кол-во выбросов растет, когда предсказательная способность модели улучшается, этим можно объяснить тот факт модели многое теряют при обычной квантизации, так как в этих экстремальных значениях много информации, которую мы теряем