

LoRA




Figure 1: Our reparametrization. We only train A and B .

LoRA обладает несколькими ключевыми преимуществами:

- Предобученная модель может быть использована для создания множества небольших LoRA-модулей для различных задач. Мы можем заморозить общую модель и эффективно переключать задачи, заменяя матрицы (A) и (B) на Рисунке 1, что значительно снижает требования к хранилищу и накладные расходы при переключении задач.
- LoRA делает обучение более эффективным и снижает аппаратные требования для начала работы до 3 раз при использовании адаптивных оптимизаторов, так как нам не нужно вычислять градиенты или поддерживать состояние оптимизатора для большинства параметров. Вместо этого мы оптимизируем только внедренные, гораздо меньшие матрицы низкого ранга.
- Наш простой линейный дизайн позволяет нам объединять обучаемые матрицы с замороженными весами при разворачивании, **не увеличивая задержку на инференсе** по сравнению с полностью дообученной моделью благодаря такой конструкции.

При finetuning'e модели мы обновляем все веса Φ , в то время как в LoRA мы обучаем лишь адаптер Φ_0 , который содержит сильно меньше обучаемых параметров

$$\max_{\Phi} \sum_{(x,y) \in \mathbb{Z}} \sum_{t=1}^{|y|} \log (P_{\Phi}(y_t|x,y_{<t})) \tag{1}$$

$$\max_{\Theta} \sum_{(x,y) \in \mathbb{Z}} \sum_{t=1}^{|y|} \log (p_{\Phi_0+\Delta\Phi(\Theta)}(y_t|x,y_{<t})) \tag{2}$$