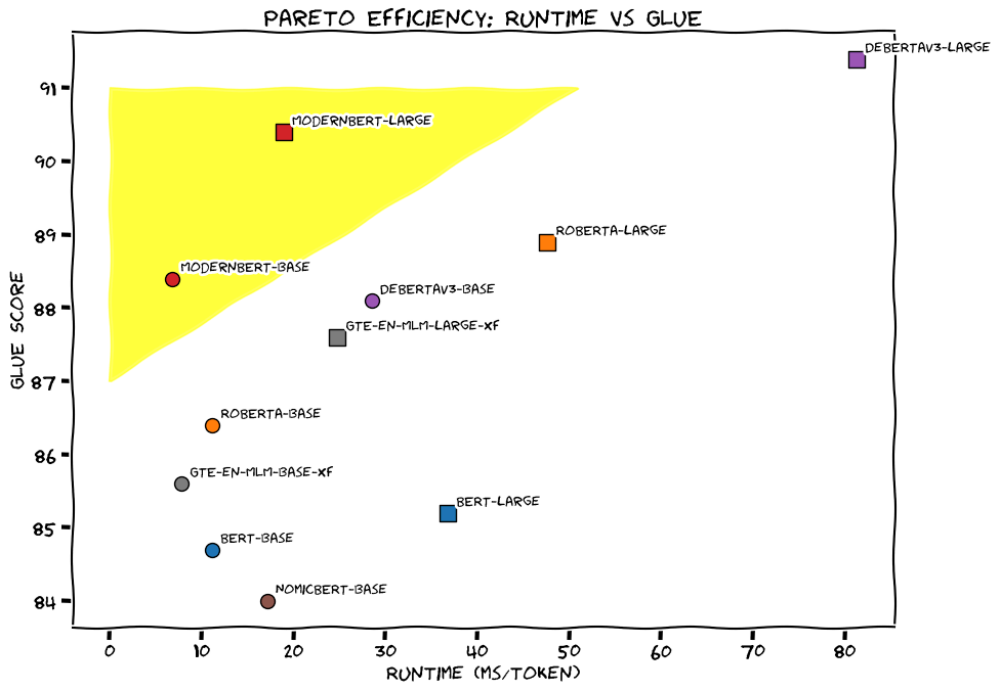


ModernBERT

Мотивация: с выхода [BERT](#) в 2018 прошло очень много времени и появилось множество инженерных улучшений, в основном области LLM(decoder only моделей), в то время как в мире encoder-only моделей давно уже не было улучшений без tradeoff'ов.



Идея авторов достаточно просто: взять все инженерные новшества, появившиеся в последнее время, и применить к encoder-only модели.

Среди них:

- модернизированная архитектура трансформера
- новые attention механики
- современные источники данных

Архитектурные улучшения


- авторы убрали bias из линейных слоев
- используют RoPE в качестве позиционных эмбеддингов
- используется pre-norm

Alternating Attention

Идея в том, чтобы сократить время рассчитывания attention слоев, поэтому авторы используют классический attention, где каждый токен "смотрит" на каждый раз в три слоя.

В остальных случаях используется sliding window attention с окном в 128 токенов.

Unpadding and sequence packing



При обычном паддинге compute тратится на токены, которые не несут никакого смысла(PAD токены), при Sequence Packing все элементы батча конкатинируются таким образом, что получается батч из одного элемента(Sequence Packing).

Обучение

1. Учат на задаче MLM(Masked Language Modeling), при этом убрав задачу NSP.
2. Токенайзер от модели OLMo
3. Vocab состоит из 50368 токенов, 83 из которых не используются($50368 = 64 * 787$, эффективнее)
4. Маскируют 30% токенов в отличие от 15% у оригинального BERT'a
5. Веса large модели в начале обучения инициализируют весами base модели
6. Сначала обучают на 1.7 триллиона токенов с длиной последовательности в 1024 токена, после чего еще на 300 миллионах токенов с длиной последовательности в 8192 токена, что позволяет добиться длины контекста в 8192 токенов(512 у BERT)