RoPE

Вид позиционного кодирования, появившийся после классического, которое было представлено в [Attention is all you need..](#).

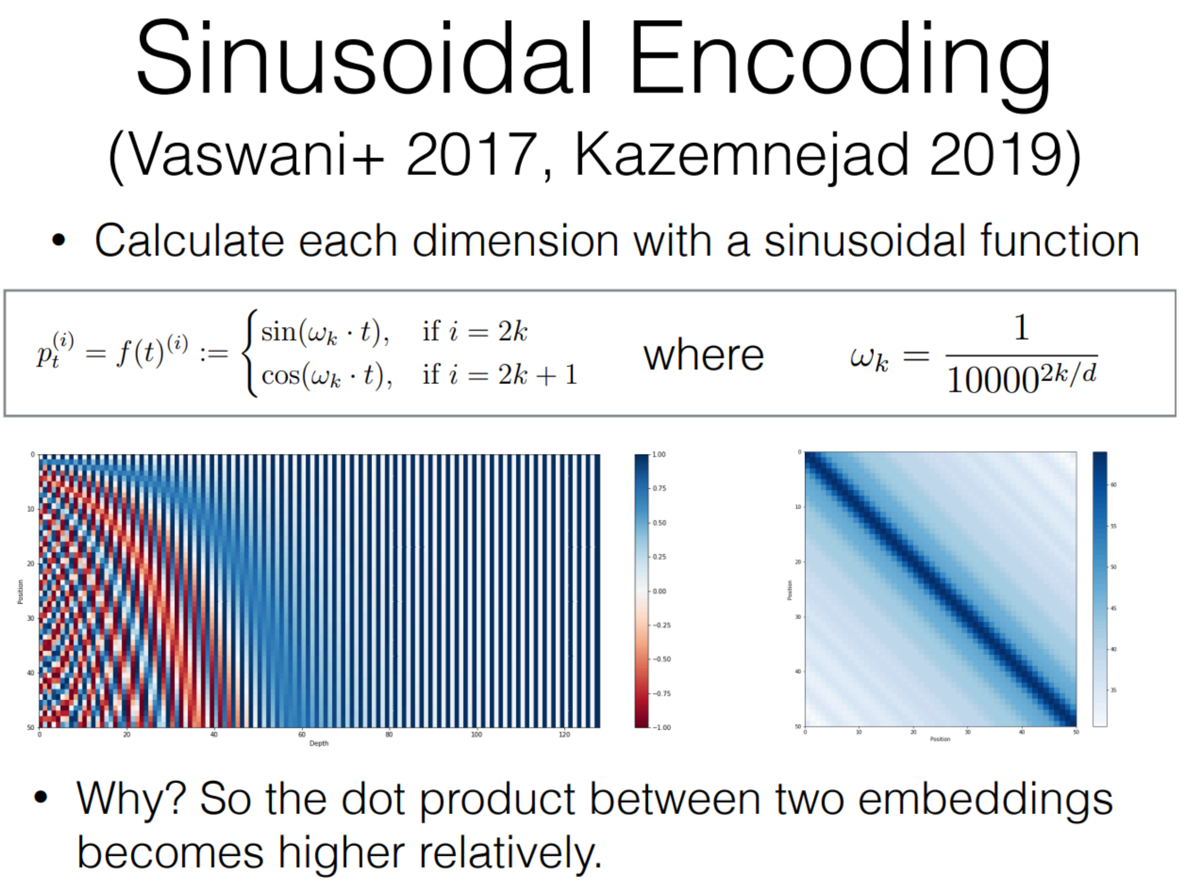

Также существует подход, когда создают отдельный обучаемый слой позиционных эмбеддингов. У этого подхода есть недостаток, который заключается в том, что после обучения невозможно экстраполировать эти данные на последовательности большей длины.

Идея Rope

Rotary Positional Encodings (RoPE)

(Su+ 2021)

- **Fundamental idea:** we want the dot product of embeddings to result in a function of relative position

$$f_q(\mathbf{x}_m, m) \cdot f_k(\mathbf{x}_n, n) = g(\mathbf{x}_m, \mathbf{x}_n, m - n)$$

Мы хотим сделать такую функцию, что после применения ее к query и key векторам, их dot-product содержит информацию об **относительных** позициях токенов, но не содеражит информацию об абсолютных.

Так выглядит преобразование для 2мерного вектора.

$$\mathbf{v}' = R(\theta) \cdot \mathbf{v} = \begin{pmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} x\cos\theta - y\sin\theta \\ x\sin\theta + y\cos\theta \end{pmatrix}$$

Обобщение для пространства размерности *d:*

$$R^d_{\Theta,m}\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ \vdots \\ x_{d-1} \\ x_d \end{pmatrix} \otimes \begin{pmatrix} \cos m\theta_1 \\ \cos m\theta_1 \\ \cos m\theta_2 \\ \cos m\theta_2 \\ \vdots \\ \cos m\theta_{\frac{d}{2}} \\ \cos m\theta_{\frac{d}{2}} \end{pmatrix} + \begin{pmatrix} -x_2 \\ x_1 \\ -x_4 \\ x_3 \\ \vdots \\ -x_d \\ x_{d-1} \end{pmatrix} \otimes \begin{pmatrix} \sin m\theta_1 \\ \sin m\theta_1 \\ \sin m\theta_2 \\ \sin m\theta_2 \\ \vdots \\ \sin m\theta_{\frac{d}{2}} \\ \sin m\theta_{\frac{d}{2}} \end{pmatrix}$$

Вектор разбивается на пары $(x_1, x_2), (x_3, x_4) \ldots (x_{d-1}, x_d)$